Задача 1. Анализ зарплат

Блок А

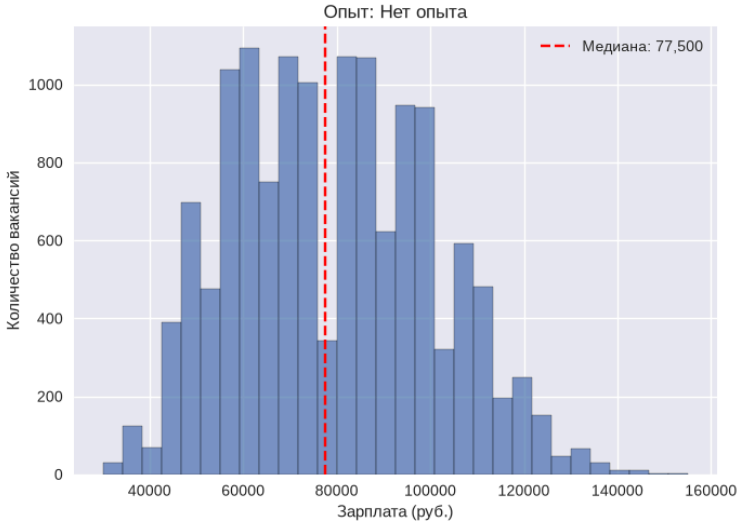
А1

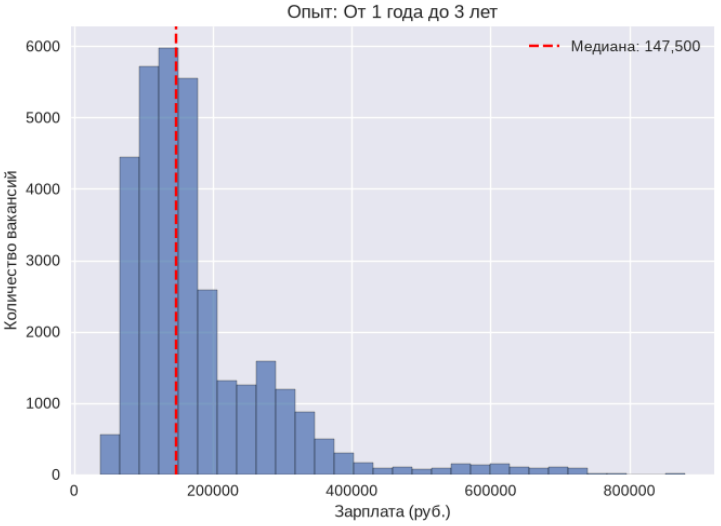
Уровень опыта	Среднее (руб.)	Медиана (руб.)	Стандартное отклонение (руб.)	25-й перцентиль (руб.)	75-й перцентиль (руб.)
Нет опыта	78622	77500	21310	60000	95000
От 1 года до 3 лет	180580	147500	112053	110000	207500
От 3 до 6 лет	176574	170000	68261	125000	222500
Более 6 лет	333409	327500	103619	255000	405000

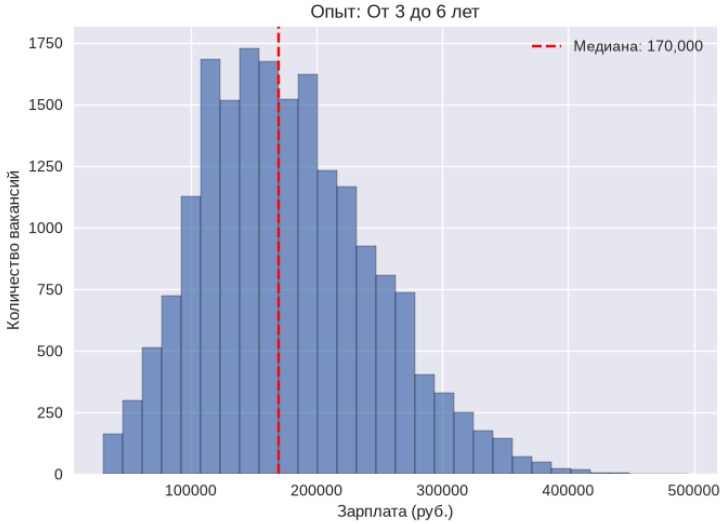
А2

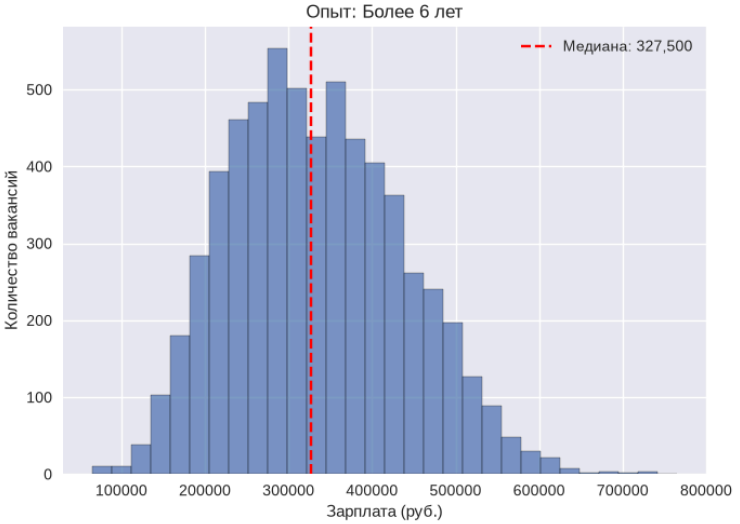
Среднее в каждой группе больше медианы. А наибольшую разницу мы наблюдаем в группе с уровнем опыта от 1 года до 3 лет.

А3









Блок B

B1

Уровень опыта	Коэффициент асимметрии
Нет опыта	0.25
От 1 года до 3 лет	2.28
От 3 до 6 лет	0.49
Более 6 лет	0.33

Сильнее всего распределение скошено в группе от 1 года до 3 лет в положительную сторону. Такой коэффициент может объясняться тем, что большая часть специалистов указала в резюме слишком большую зарплату, из-за чего и мог случиться такой сильный перекос.

B2

Мы наблюдаем именно такое расхождение из-за того, что среднее более чувствительно к выбросам. В то время, как медиана устойчива к ним, потому что является серединным числом, которое делит все заработные платы ровно пополам (то есть 50% чисел меньше нее самой и 50% больше).

Расхождение напрямую связано с коэффициентом асимметрии, большая часть аналитиков в этой группе опыта, получает относительно небольшую зарплату и существует группа специалистов, у которых при том же опыте заработная плата в разы больше.

B3

Для подсчета разброса зарплат будем использовать межквартильный размах (IQR), так как он не зависит от выбросов.

Уровень опыта	IQR (руб.)
Нет опыта	35000
От 1 года до 3 лет	97500
От 3 до 6 лет	97500
Более 6 лет	150000

Наибольший разброс зарплат в группе с самым большим опытом.

Наиболее вероятно кандидат сможет предсказать зарплату в группе “Нет опыта”, так как там наблюдается наименьший размах. То есть у 50%

кандидатов в группе без опыта, различие в заработной плате укладывается в 35 тысяч рублей. В группах же с большим опытом, предугадать зарплату намного тяжелее.

Блок C

C1

Для описания типичной зарплаты в каждой группе правильнее использовать медиану. Это объясняется тем, что все группа с опытом от 1 года до 3 лет имеет очень сильную правую асимметрию, то есть имеется небольшая группа аналитиков, указавшая экстремально огромную заработную плату, по сравнению с общей массой, из-за чего, среднее получилось чересчур завышенным. Группы с опытом от 3 до 6 лет и от 6 лет, имеют более умеренную асимметрию, но все равно остается перекос. Именно поэтому лучше ориентироваться на медиану.

C2

Нет, Вася не должен доверять этой цифре, поскольку среднее слишком сильно зависит от экстремальных показателей зарплаты, то есть выбросов. Васе следует ориентироваться на медиану и межквартальных размах, а самое главное на основе какого количества резюме или вакансий проведен расчет среднего. Если датасет небольшой, то такие расчеты нельзя считать правдоподобными.

C3

Нет, по имеющимся данным нельзя утверждать, что зарплаты аналитиков с опытом “От 3 до 6 лет” значимо выше, чем у аналитиков “От 1 года до 3 лет”.

Для однозначного ответа можно было бы провести U-тест Манна-Уитни, который помогает оценить степень различий между выборками данных, когда они сильно скошены и имеют выбросы. Помимо этого, можно было разделить датасет на две группы, где первой группой выступят регионы, а второй столицы - Москва и Санкт-Петербург, ведь зарплаты в регионах и крупных городах могут сильно различаться.

Блок D

D1

Я бы рекомендовал Васе использовать в качестве “средней зарплаты по рынку” медиану из группы “От 1 года до 3 лет”, так как эта цифра наиболее приближена к настоящим зарплатам в этом грейде. Из-за того, что он находится только в самом начале этого грейда, ему не следует

рассчитывать на такую же зарплату, как у более опытных коллег из этой группы, но и на меньшую, как у аналитиков “Без опыта” ему соглашаться не нужно.

D2

Зарплата Васи в его грейде “От 1 года до 3 лет” является наиболее непредсказуемой из всех других грейдов. Об этом говорит и коэффициент асимметрии и межквартильный размах.

Самая низкая неопределенность в зарплатах наблюдается в группе аналитиков “Без опыта”, о чем говорят те же самые характеристики.

Скорее всего, Вася найдет работу в своем грейде, но она вряд ли будет сильно выше медианы, ведь он еще не настолько опытен.

D3

1. Искать зарплату в своем грейде. Не нужно рассматривать вакансии из группы “Без опыта” или групп выше.
2. Использовать зарплатную вилку от медианы до 75-го перцентиля, чтобы на собеседовании Вася смог выбить для себя наиболее выгодные условия.

Задача 2. Пост в “Сетке”

Блок А

A1

P(нашел работу в первый месяц | ученик автора) = 0.78. Словами это значит следующее: вероятность того, что человек нашел работу в первый месяц, при условии, что он ученик автора составляет 0.78.

Противоположная вероятность равна 0.22 $(1 - 0.78)$. Она описывает $200 \times 0.22 = 44$ ученика автора.

A2

P(указал в резюме SQL и Python | получил оффер) = 0.85.

Событие A - указал в резюме SQL и Python.

Событие B - получил оффер.

Нам известна вероятность указания SQL и Python в резюме, у ученика, который уже получил оффер.

A3

P(отклик в оффер) = 0.1

P(отказ в оффере) = 0.9

1. P(1 отклик сразу станет оффером) = 0.1
2. P(2 отклика подряд не станут офферами) = $0.9 \times 0.9 = 0.81$
3. P(5 откликов подряд будут отказами) = $0.9^5 = 0.59049$

Блок В

B1

Автору известна вероятность указания SQL и Python в резюме, у уже получивших оффер учеников. Чтобы сделать вывод, который делает автор, ему нужна другая условная вероятность:

P(получил оффер | указал SQL и Python в резюме). А это разные вероятности. Событие A - указал SQL и Python в резюме; Событие B - получил оффер.

Для того, чтобы сделать такой вывод, автору не хватает информации о вероятности указания SQL и Python в резюме, так как:

P(B|A) = $\frac{P(A \bullet B)}{P(A)}$. P(A•B) мы найдем с помощью условной вероятности P(A|B) и P(получил оффер), которая нам известна из поста.

B2

Во-первых, выборка покрывает не всех его студентов, а лишь небольшую часть. Во-вторых, пройти опрос могла часть самых сильных и

успешных студентов, в то время как другая часть могла его проигнорировать или они вовсе могли быть не опрошены.

Скорее всего, эта цифра систематически завышена, потому что большая часть людей не приняла участие в опросе и нет никаких сравнений с группами, которые не проходили этот курс, но также трудоустроились.

Я бы попытался собрать максимально большую выборку из всех студентов, кто успешно закончил курс, кто бросил. Сделал бы рассылку на почты, в личных сообщениях и в группе курса например (или на сайте, если такой был бы). Кроме этого, еще бы собрал данные о людях, не проходивших мой курс и проанализировал бы, какая часть из них смогла трудоустроиться. И уже на базе этих данных делал бы выводы об эффективности своего курса.

B3

Это утверждение неверно, ведь вероятность не получить оффер просто будет уменьшаться вместе с ростом числа откликов, но никогда не станет равной нулю.

Автор неявно предполагает, что с количеством отказов растет вероятность получить оффер, но это не так, ведь каждый отклик не зависит от предыдущего и вероятность получения оффера не будет меняться в зависимости от числа отказов.

Вывод о том, что Вася точно получит оффер неверно. Его шансы могут как повышаться, так и понижаться, в зависимости от ситуации на рынке аналитиков и улучшения его навыков и резюме.

Блок C

C1

Нет, это утверждение неверно. P(хотя бы 1 оффер за 20) = 1 - P(ни одного оффера за 20 откликов) = $1 - 0.9^{20} = 0.8784$.

Данная задача сводится к биномиальному распределению.

$1 - 0.9^{n} \geq 0.95$

$0.9^{n} \leq 0.05$

$n \geq log_{0.9} 0.05$

$n \geq ln(0.05) \div ln(0.9) \approx 28.43$

То есть для вероятности хотя бы в 95% нам необходимо сделать 29 откликов.

C2

Если судить по факту 3, то это число испытаний до первого успеха, то есть геометрическое распределение.

Медиана для геометрического распределения считается по формуле: Медиана $= \frac{log(2)}{log(1-p)}$, где p - вероятность успеха, равная 0.029 ($1 \div 35$, по формуле для нахождения среднего для геометрического распределения, нужно 1 разделить на вероятность успеха p, отсюда мы и находим вероятность успеха). Тогда медиана будет равна 24. Благодаря этой информации, мы можем сделать вывод, что распределение скошено вправо.

Если у вас 35 откликов и нет оффера, это не значит, что с кандидатом что-то не так, ведь если посчитать, довольно большое число аналитиков подает больше 35 откликов, ведь вероятность не получить ни одного оффера равна $(1 - 0.029)^{35} \approx 0.36$, а это чуть больше трети от всех кандидатов.

По одному среднему числу нельзя делать вывод о норме, ведь оно очень сильно зависит от выбросов.

Блок D

D1

Факт №	Ошибка	Вывод
1	Малая выборка студентов для опроса, без контрольной группы и независимой проверки	78% - лишь красивая цифра, а не доказательство высокой эффективности курса
2	Перепутаны условные вероятности P(A|B) и P(B|A)	Мы не знаем какова вероятность получения оффера, при условии, что в резюме указаны SQL и Python
3	Среднее считается главным показателем	Среднее сильно зависит от выбросов, поэтому нельзя ориентироваться только на него
4	Гарантированное получение оффера после 20 откликов	Вероятность получения оффера вычисляется иначе: $1 - 0.9^{20}$

5	Автор неявно предполагает, что с количеством отказов растет вероятность получить оффер	Это не так, ведь каждый отклик не зависит от предыдущего и вероятность получения оффера не будет меняться в зависимости от числа отказов.

Комментарий Вовы:

Хотел бы отметить, что в своем посте автор допускает несколько недочетов, если смотреть на со стороны теории вероятностей. Автор опросил только своих учеников и только малую их часть, причем отвечали, скорее всего, самые успешные - это смещение выборки, и 78% явно завышены. Ещё тут путаница с вероятностями: из того, что 85% получивших оффер знают SQL, не следует, что знание SQL дает 85% шанс на оффер. И уж точно нельзя говорить про “гарантированный оффер после 20 откликов” — там вероятность примерно 88%, а не 100%. А фраза “после 10 отказов следующий точно даст оффер” - это ошибка, ведь отклики не зависят друг от друга, и шанс на 11-й попытке такой же, как на первой.

D2

а) Вове надо отправлять по 10-15 откликов каждую неделю, то есть 2-3 в день. Так как при конверсии в 10% для 95% вероятности нужно 29 откликов, а такого количества откликов Вова сможет достичь достаточно быстро за 2-3 недели поиска работы, что довольно оптимально.

б) В одном режиме Вове стоит работать 3 недели. За это время он сможет набрать 30-45 откликов, что выше медианы и близко к среднему, если на момент набора такого количества откликов Вова не получит оффер, то это сигнал к смене режима.

в)

Сигнал	Значение	Действие
0 ответов на 35 и более откликов	Нерелевантное резюме	Переписать резюме под конкретные предложения, добавить ключевые навыки вакансии
20 и более откликов, есть приглашения на собеседования, но 0	Плохо помнит базу или инструменты для работы, не может	Повторить базу, необходимые инструменты,

офферов	хорошо себя представить	смотреть разборы чужих собеседований, проводить пробные собеседования, прокачать soft-скиллы
20 и более откликов, офферы есть, но мало	Высокая конкуренция и перенасыщение рынка	Смотреть не только в сторону больших компаний, искать работу не только в своем городе

D3

а)

Предположение	Если неверно
Отклики независимы	Если Вова учится на отказах, продолжает развиваться, то шансы повышаются
Конверсия Вовы примерно 10%	Если ниже, то нужно больше откликов в неделю
Рынок стабилен	Если рынок перенасыщен аналитиками, то конверсия падает
Резюме релевантно	30-45 откликов не дадут никакого результата

б)

1. Кризис на рынке: вакансий мало, конкуренция высокая, даже 100 откликов могут не дать оффера.
2. Смена профессии: опыт Вовы нерелевантен, конверсия будет почти нулевой.
3. Высокий грейд: если Вова метит на senior-аналитика, а опыта мало, то любого количества откликов может не быть оффера - он просто не сможет пройти собеседования.
4. Отсутствие обратной связи: без анализа отказов стратегия не корректируется.

в) Хотел бы получить:

1. Личную конверсию Вовы, чтобы на ее основе строить частоту и количество откликов
2. Данные о его уровне и количеству вакансий на рынке труда
3. Обратную связь работодателей в случае отказа