Задание 1.

Вася — студент последнего курса, уже имеет год опыта работы продуктовым аналитиком, но планирует менять место работы. Прежде чем рассылать резюме, он хочет разобраться в рынке: понять, как зарплаты зависят от опыта, насколько они предсказуемы и на что вообще ему рассчитывать.

Вася выгрузил с hh.ru 100000 вакансий аналитика данных и просит тебя помочь ему разобраться в этих данных.

Датасет: vacancies.csv, 100000 строк.

Колонка	Тип	Описание
vacancy_id	int	Идентификатор вакансии
salary_from	float	Нижняя граница зарплатной вилки, ₽ (может отсутствовать)
salary_to	float	Верхняя граница зарплатной вилки, ₽ (может отсутствовать)
experience	str	Требуемый опыт: Нет опыта / От 1 года до 3 лет / От 3 до 6 лет / Более 6 лет
city	str	Город вакансии
employment_type	str	Тип занятости: Полная занятость / Частичная занятость / Стажировка / Удалённая работа

Зарплата может быть указана как полной вилкой (salary_from и salary_to), так и одной границей, либо отсутствовать. Как корректно работать с этим — твоё методологическое решение, опиши его в ответе. Так как Вася выгружал всё самостоятельно, он не ручается, что нет ошибок парсинга.

Блок A. Технический

A1. Посчитай основные описательные статистики зарплат отдельно по каждому уровню опыта: среднее, медиану, стандартное отклонение, 25-й и 75-й перцентили. Представь результат в виде таблицы.

A2. Сравни значения среднего и медианы внутри каждой группы. Что ты замечаешь? Опиши наблюдение в одном-двух предложениях.

A3. Построй гистограммы распределения зарплат для каждого уровня опыта. Размести их так, чтобы группы можно было визуально сопоставить друг с другом.

Блок B. Аналитический

B1. Посчитай коэффициент асимметрии (skewness) для распределения зарплат в каждой группе опыта. В каких группах распределение скошено сильнее всего? В какую сторону? Чем это может объясняться?

B2. Объясни, почему в результатах из A2 среднее и медиана расходятся именно таким образом. Как это расхождение связано со скошенностью, которую ты посчитал в B1?

B3. В какой группе разброс зарплат наибольший? Посчитай его, используя нужные метрики. Что это означает для кандидата, который хочет предсказать свою будущую зарплату, ориентируясь на эти данные?

Блок C. Интерпретация

C1. Какую метрику (среднее, медиану или может что-то третье) правильнее использовать для описания «типичной» зарплаты в каждой группе? Обоснуй выбор, опираясь на форму распределения, которую ты обнаружил в блоках A и B.

C2. Вася нашёл в интернете статью, где написано: «средняя зарплата аналитика данных с опытом 1–3 года — N рублей». Должен ли он доверять этой цифре? Какие методологические оговорки стоит сделать?

C3. Можно ли по имеющимся данным утверждать, что зарплаты аналитиков с опытом «От 3 до 6 лет» значимо выше, чем у аналитиков с опытом «От 1 года до 3 лет»? Если да, то на каком основании. Если нет, то каких данных или инструментов не хватает, чтобы ответить на этот вопрос строго?

Блок D. Рекомендация

D1. Вася собирается на собеседование и хочет назвать «среднюю зарплату по рынку» при обсуждении оффера. Какую именно цифру ему использовать и как её корректно интерпретировать с учётом того, что ты узнал о форме распределения зарплат? Дай конкретную рекомендацию и обоснуй её.

D2. Глядя на разброс зарплат внутри грейдов: насколько предсказуема зарплата Васи, если он выйдет на рынок прямо сейчас? Где неопределённость выше, где ниже? Что это означает для его стратегии поиска работы?

D3. Сформулируй 2–3 конкретных вывода для Васи в виде коротких тезисов: что ему делать с этой аналитикой на практике.